

Tarefa II

Manuel Ferreira Junior, 20180008601


maio 12, 2021 - 11:50:22

Exercicio I:

```
n = 500; et = rnorm(n); yt = numeric(n)
yt[1] = (1/3)*(et[1] + et[2]); yt[500] = (1/3)*(et[499] + et[500])
for (i in 2:499){
  yt[i] = (1/3)*(et[i-1] + et[i] + et[i + 1])
}
```

A)

```
plot.ts(yt, ylab=expression(y[t]), xlab='Tempo')
```

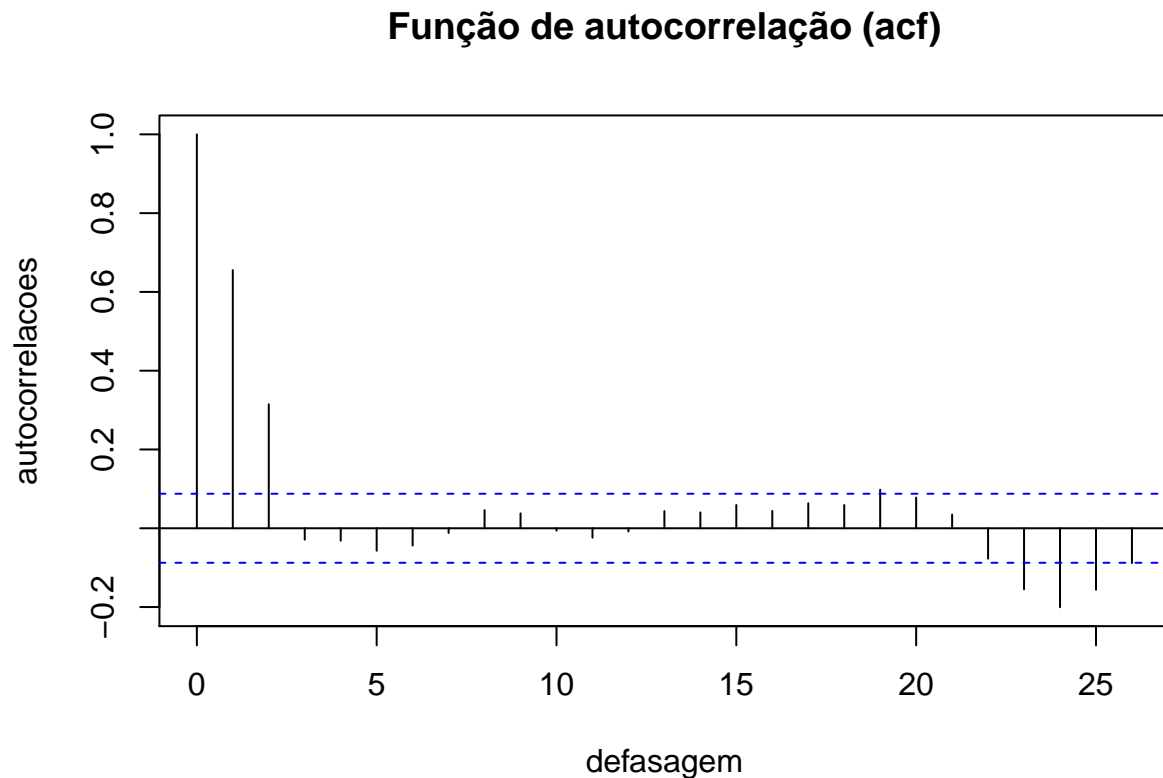


B)

Demonstração no final do pdf, anexado.

C)

```
obj = acf(yt, main='Função de autocorrelação (acf)',  
          xlab="defasagem", ylab="autocorrelacoes")
```



Apos a demonstração do item (B), temos a seguinte situação:

$$Cov(y_t, y_{t-k}) = \begin{cases} \frac{\sigma^2}{3}, & k = 0 \\ \frac{2 \cdot \sigma^2}{9}, & |k| = 1 \\ \frac{1 \cdot \sigma^2}{9}, & |k| = 2 \\ 0, & |k| > 2 \end{cases}, \text{ tal que } k \in \mathbb{Z}$$

$$Corr(y_t, y_{t-k}) = \begin{cases} 1, & k = 0 \\ \frac{2}{3}, & |k| = 1 \\ \frac{1}{3}, & |k| = 2 \\ 0, & |k| > 2 \end{cases}, \text{ tal que } k \in \mathbb{Z}$$

Antes de analisarmos o *ACF* e a demonstração realizada, podemos verificar que a série apresenta um comportamento estacionário, sendo ela centrada em um valor esperado, e apresentando uma variância constante, fato este demonstrado durante o item (B) do Exercício I, sendo a variância constante, então $Var(Y_t) = \frac{\sigma^2}{3}$ e a esperança centrada em zero, então $E[Y_t] = 0$.

Ao compararmos com o gráfico *ACF* obtido, podemos ver o decaimento das autocorrelações ao longo das defasagens; Ao analisarmos a demonstração, é esperado que para uma defasagem estritamente superior a 2, as

correlações sejam zero, porém no gráfico conseguimos ver que seu decaimento é rápido para 0 após a segunda defasagem. Além disso, podemos notar que a maior correlação, dado essa equação para y_t , é para com a primeira defasagem, sendo aproximadamente 0.66, e para a segunda defasagem temos um valor aproximado de 0.33, logo após isso o decaimento é rápido em direção a zero.

Exercicio II:

```
install.packages("astsa")

## Installing package into '/home/manuel/R/x86_64-pc-linux-gnu-library/4.0'
## (as 'lib' is unspecified)

library(astsa)

help(chicken)


data("chicken")
serie = chicken

model = lm(chicken ~ time(chicken))
summary(model)

##
## Call:
## lm(formula = chicken ~ time(chicken))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8.7411 -3.4730  0.8251  2.7738 11.5804
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -7.131e+03  1.624e+02  -43.91  <2e-16 ***
## time(chicken)  3.592e+00  8.084e-02   44.43  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.696 on 178 degrees of freedom
## Multiple R-squared:  0.9173, Adjusted R-squared:  0.9168
## F-statistic: 1974 on 1 and 178 DF, p-value: < 2.2e-16

plot.ts(chicken,xlab='Tempo',ylab='Preço do frango',lty=1)
abline(model,col='red',lty=1)
grid()
legend(2002, 115, legend=c("Preço do frango pelo tempo", "Reta ajustada"),
      col=c("black", "red"), lty=c(1,1), cex=0.8, text.font=4, bg='lightgray')
title('Gráfico do preço de frango nos Estados Unidos versus o tempo
      e da reta ajustada')
```

Gráfico do preço de frango nos Estados Unidos versus o tempo e da reta ajustada



A)

- Teste t

$$h_0 : \beta_i = 0$$


$$h_1 : \beta_i \neq 0$$

Podemos notar que, a um nível de significância de 5%, rejeitamos a hipótese nula considerando o teste t para os parâmetros, ou seja, há evidências suficientes para afirmar de que o tempo é um variável estatisticamente significativa para poder explicar o preço do frango nos Estados Unidos, existindo uma dependência positiva, evidenciado pelo valor de $\beta > 0$, ou seja, a cada incremento de tempo, temos um aumento estimado do preço de frango nos Estados Unidos de em média \$ 3,59. Por fim, por rejeitarmos a hipótese nula para todos os parâmetros do modelo, temos que nosso modelo é estatisticamente significativo.

Além disso, ao analisarmos o nosso coeficiente de determinação obtido pelo modelo, podemos dizer que o mesmo apresenta um alto poder explicativo, ou seja, o modelo consegue explicar bem a variabilidade das observações, conseguindo explicar cerca de 91.73% da variabilidade dos dados.

B)

```
plot.ts(chicken, xlab='Tempo', ylab='Preço do frango')  
title('Série temporal do preço do frango nos Estados Unidos')  
grid()
```



C)

```
PP.test(chicken)
```

```
##  
## Phillips-Perron Unit Root Test  
##  
## data: chicken  
## Dickey-Fuller = -2.5418, Truncation lag parameter = 4, p-value = 0.3498
```

Ao analisarmos todos os itens anteriores, graficamente podemos observar que a série não está centrada em torno de um valor esperado e nem apresenta uma variância constante ao longo do seu comportamento, evidenciando uma violação de um comportamento estacionário.

Ao realizarmos o teste de Phillips-Perron, temos que, a um nível de significância de 5%, não rejeitamos a hipótese nula, ou seja, há evidências suficientes para afirmar que a série é não estacionária, sendo essa a hipótese nula do teste realizado, então podemos afirmar que a série não está centrada em um valor constante, observado pelo seu crescimento ao longo do tempo.